

Analisi statistica del Campionato Mondiale di F1 2017

Politecnico di Milano
Corso di Statistica - Prof. Alessandro Toigo



Chiacchiari Davide, Gumirato Gianluca, Rosini Andrea

Anno accademico 2021/2022

Indice

1	Introduzione	3
2	Statistica Descrittiva	4
3	Analisi dell’Australian Grand Prix	8
4	Inferenza statistica	13
4.1	Confronto GP Australiano e Belga	13
4.2	Confronto GP Australiano e Cinese	14
5	Regressione lineare multipla	18
5.1	Costruzione di un modello	18
5.2	Previsione sugli ultimi tempi	24
6	Conclusioni	25
7	Bibliografia e Risorse	26

Elenco delle figure

1	Tempi medi dei piloti nelle gare	5
2.2	Boxplot prima gara	6
2.3	Boxplot seconda gara	6
2.4	Boxplot dodicesima gara	7
3.1	Boxplot dei tempi di Hamilton nella prima gara	8
3.2	Boxplot dei tempi di Vettel nella prima gara	8
3.3	Boxplot dei tempi di Bottas nella prima gara	9
3.4	Grafici Quantile-Quantile dei tempi dei piloti	11
3.5	Grafici Quantile-Quantile dei tempi dei piloti escludendo gli outlier	12
4.1	Confronto gare di Hamilton con la pioggia	15
4.2	Confronto gare di Vettel con la pioggia	16
4.3	Confronto gare di Bottas con la pioggia	16
4.4	Shapiro-Wilk Test sui tempi di Hamilton	16
4.5	Shapiro-Wilk Test sui tempi di Vettel	17
4.6	Shapiro-Wilk Test sui tempi di Bottas	17
5.1	Resoconto del primo modello	18
5.2	Residui e Quantili del primo modello	19
5.3	Resoconto secondo modello	21
5.4	Residui e Quantili del secondo modello	21
5.5	Resoconto terzo modello	22
5.6	Residui e Quantili terzo modello	22
5.7	Resoconto modello definitivo	23
5.8	Residui e Quantili modello definitivo	23

1 Introduzione

Presentiamo uno studio rivolto all'analisi del Campionato Mondiale di Formula 1 del 2017. L'obiettivo di questo studio è innanzitutto quello di capire con che livello di difficoltà si riesca a prevedere l'esito di una o più gare di Formula 1. Ci occuperemo poi di applicare la statistica effettuata sulle ultime due gare del campionato 2017. Per la realizzazione dei grafici e modelli a seguire, ci siamo serviti del supporto computazionale del software statistico R, dei siti *Advanced Boxplot Maker* e *Onlinecharttool*, del linguaggio di marcatura LaTeX e il software MatLab per la gestione di dati. Innanzitutto occupiamoci di spiegare come applicheremo la statistica. Come è noto, il campionato di Formula 1 è costituito da 20 gare che vengono disputate nell'arco dell'anno solare in tutto il mondo. Guardando i risultati del campionato 2017 ci accorgiamo che questo si chiuse alla fine della diciottesima gara; più nello specifico, considerando i piloti Hamilton, Vettel e Bottas (che quell'anno hanno concluso il campionato sul podio), notiamo che alla vigilia della diciottesima gara, Hamilton conduceva la classifica con 66 punti di vantaggio su Vettel; per aggiudicarsi il campionato era necessario:

- giungere tra i primi 5;
- giungere tra il sesto e il nono posto, con Vettel al massimo secondo;
- giungere decimo o peggio, con Vettel al massimo terzo.

La gara si concluse con un quarto posto di Vettel che consegnò automaticamente al pilota inglese il titolo di campione del mondo. Le ultime due gare quindi si disputarono a campionato praticamente concluso e a classifica per la maggior parte già definita. È legittimo pensare che la mancanza della motivazione di scalare la classifica possa aver influito nella mentalità dei piloti. Vogliamo quindi chiederci: stando ai dati delle sole prime 18 gare, analizzando i tempi di ogni giro di ogni gara e tenendo conto del numero di curve delle varie piste e del fattore pioggia, quali avrebbero dovuto essere i risultati attesi dei tre piloti nelle ultime due gare?

2 Statistica Descrittiva

Gara	Gran Premio	Nazione	Sede
1	Rolex Australian Grand Prix	Australia	Melbourne
2	Heineken Chinese Grand Prix	Cina	Shanghai
3	Gulf Air Bahrain Grand Prix	Bahrain	Manama
4	VTB Russian Grand Prix	Russia	Sochi
5	Gran Premio de España Pirelli	Spagna	Montmeló
6	Grand Prix de Monaco	Monaco	Monaco
7	Grand Prix du Canada	Canada	Montréal
8	Azerbaijan Grand Prix	Circuito di Baku	Baku
9	Großer Preis von Österreich	Austria	Spielberg
10	Rolex British Grand Prix	Regno Unito	Silverstone
11	Pirelli Magyar Nagydíj	Ungheria	Mogyoród
12	Pirelli Belgian Grand Prix	Belgio	Stavelot
13	Gran Premio Heineken d'Italia	Italia	Monza
14	Singapore Airlines Singapore Grand Prix	Singapore	Singapore
15	Petronas Malaysia Grand Prix	Malesia	Sepang
16	Japanese Grand Prix	Giappone	Suzuka
17	United States Grand Prix	Stati Uniti d'America	Austin
18	Gran Premio de México	Messico	Città del Messico
19	Grande Prêmio Heineken do Brasil	Brasile	San Paolo
20	Etihad Airways Abu Dhabi Grand Prix	Emirati Arabi Uniti	Abu Dhabi

Tabella 1: Elenco dei Gran Premi

Iniziamo col presentare i dati utilizzati per la statistica: le gare inizialmente prese in considerazione sono le prime 18, visionabili in questa tabella. Per comodità da qui in poi, riferendoci alle gare, invece del nome della gara useremo il numero corrispondente, dati dall'ordine cronologico in cui si sono disputati i Gran Premi.




Figura 1: Tempi medi dei piloti nelle gare

Nell'ortogramma qui sopra abbiamo riportato i **tempi medi** di ogni giro delle prime cinque gare, la gara 12 e la gara 16. La prima osservazione che è doveroso fare riguarda la colonna relativa alla gara 16 di Vettel, di gran lunga più alta rispetto a quella della gara 16 dei suoi avversari. In quella gara la macchina di Vettel riscontrò un problema a una candela che costrinse il pilota tedesco al ritiro dopo soli quattro giri; poiché nel grafico sono riportati i tempi medi, e di Vettel si hanno a disposizione solo i tempi di quattro giri (uno di questi è il giro di partenza e un altro è stato percorso con la safety car), è legittimo aspettarsi per lui un tempo medio molto elevato. Dopo aver fatto una considerazione sui tempi medi, occorre concentrarsi sui tempi di ogni giro per comprenderne meglio la distribuzione. Abbiamo preso in analisi tre gare in particolare (1, 2 e 12) e realizzato quindi in ogni gara un boxplot per pilota, per un totale di 9 boxplot. E, di seguito, alcuni grafici relativi alle caratteristiche dei circuiti presi in considerazione:




Figura 2.2: Boxplot prima gara




Figura 2.3: Boxplot seconda gara





Figura 2.4: Boxplot dodicesima gara



3 Analisi dell'Australian Grand Prix

Concentriamoci inizialmente sul pilota Hamilton, e rappresentiamo il boxplot dei tempi relativi alla sua gara:




Figura 3.1: Boxplot dei tempi di Hamilton nella prima gara

Notiamo la presenza di 4 outliers, individuiamoli e trascriviamoli nella tabella seguente:

Tempi	94404	106345	93568	91474
Giri	1	17	18	24

Tabella 2: Tabella dei dati anomali della prima gara di Hamilton

Ripetiamo le stesse operazioni per Vettel:




Figura 3.2: Boxplot dei tempi di Vettel nella prima gara

I cui outlier sono:

Tempi	95078	106995	93830
Giri	1	23	24

Tabella 3: Tabella dei dati anomali della prima gara di Vettel

Arriviamo a Bottas:




Figura 3.3: Boxplot dei tempi di Bottas nella prima gara

e relativi outlier:

Tempi	96009	106647	93438
Giri	1	25	26

Tabella 4: Tabella dei dati anomali della prima gara di Bottas

Ecco le osservazioni che possiamo dedurre dal momento che si possono notare alcune somiglianze fra i boxplot dei 3 piloti:

- il numero degli outlier è uguale o comunque simile (4 per Hamilton, 3 per Bottas e Vettel);
- il tempo del primo giro è sempre un outlier;
- gli outlier successivi si trovano intorno alla posizione 24, si differenzia leggermente Hamilton per la presenza di due outlier per i giri 17,18;
- per tutti e 3 i piloti si possono trovare 2 outlier che corrispondono a 2 giri consecutivi;
- per tutti e 3 i piloti è presente un giro di durata quasi 20 secondi maggiore rispetto agli altri.

Cerchiamo di dare una spiegazione a questi aspetti in comune. Il fatto che il tempo del primo giro sia un outlier non ci deve sorprendere: i piloti non solo partono da fermi, ma anche in posizione ravvicinata, è facile immaginare che il primo giro sia sempre caratterizzato da un alto livello di *traffico*.

Il giro più lento di ogni pilota corrisponde al giro in cui il pilota ha effettuato il pit-stop. Un pit-stop per quattro pneumatici e carburante può durare dai 12 ai 16 secondi; inoltre bisogna considerare che il pilota possa perdere dell'ulteriore tempo nel momento di rientro in pista. Il numero minimo di pit-stop previsti da regolamento per una gara è 1, a volte se ne effettuano 2 e in casi eccezionali 3. Dai dati possiamo evincere che in questa gara ognuno dei 3 piloti ha effettuato un pit-stop: Hamilton al giro 17, Bottas al giro 25 e Vettel al giro 23.


Notiamo che il giro successivo a quello del pit-stop rappresenta anch'esso un outlier, questo è sempre dovuto al fatto che nel rientro in gara si possa andare incontro a rallentamenti dovuti al traffico delle macchine che sopraggiungono.

Gara	Pilota	Numero di pit-stop	Giro	Durata [s]
1	Hamilton	1	17	21.709
1	Vettel	1	25	21.440
1	Bottas	1	23	21.998

Tabella 5: Dati relativi ai pit-stop

Consultando la pagina Wikipedia della gara in questione, scopriamo che a causa della fermata ai pit-stop, Hamilton venne superato momentaneamente da un altro pilota, Verstappen, che per alcuni giri gli rimase davanti rallentandolo. Questo spiega i giri più lenti di Hamilton a seguito del pit-stop. In altre gare il numero di tempi anomali è ancora maggiore, non è infatti raro che si verifichino incidenti che costringono i piloti a rallentare per uno o più giri.

Valutiamo la gaussianità dei nostri dati:







Figura 3.4: Grafici Quantile-Quantile dei tempi dei piloti

Pilota	p-value
Hamilton	3.915e-13
Vettel	5.729e-14
Bottas	8.013e-13

Tabella 6: Test di Shapiro-Wilk

Sia i Q-Q plot che i test di Shapiro-Wilk escludono la normalità dei 3 campioni.

Ripetiamo ora la stessa verifica utilizzando i dati privati degli outlier individuati precedentemente:






Figura 3.5: Grafici Quantile-Quantile dei tempi dei piloti escludendo gli outlier

Pilota	p-value
Hamilton	0.07305
Vettel	0.2959
Bottas	0.01204

Tabella 7: Test di Shapiro-Wilk escludendo gli outlier

Non riusciamo ancora ad ottenere dei campioni approssimativamente normali, ma è evidente come escludendo gli outlier il livello di gaussianità sia aumentato. Per Hamilton e Bottas la normalità è poco verosimile, per Vettel ($p\text{-value} > 10\%$) non possiamo escluderla, ma di certo non ci sono forti evidenze a suo favore.

Dopo aver analizzato e giustificato la presenza di outlier nei campioni, d'ora in poi considereremo solo i dati privati dei valori anomali al fine di ignorare giri lenti dovuti a particolari situazioni quali incidenti, pit-stop o traffico eccessivo, e in modo da lavorare su tempi che descrivono unicamente l'abilità del pilota e le prestazioni della sua vettura.

4 Inferenza statistica

4.1 Confronto GP Australiano e Belga

Nella gara considerata (Gran Premio di Australia 2017), i tempi medi per ogni pilota sono i seguenti:

GP	Hamilton	Vettel	Bottas
Australia	88223.7	88223.8	88223.9

Tabella 8: Tempi Medi Gran Premio Australiano

Osserviamo alcune caratteristiche relative al circuito in cui si è svolta la gara:

GP	Curve	Km	Numero di giri
Australia	16	5.303	57

Tabella 9: Gran Premio Australiano caratteristiche

Ripetiamo le stesse osservazioni per un'altra gara dello stesso anno, il Gran Premio del Belgio 2017, il cui circuito rappresenta il più lungo di tutto il campionato e uno di quelli con più curve:

GP	Hamilton	Vettel	Bottas
Belgio	108916.8	108910	109396.1

Tabella 10: Tempi Medi Gran Premio Belga

GP	Curve	Km	Numero di giri
Belgio	20	7.004	44

Tabella 11: Gran Premio Belga caratteristiche

I valori medi riportati rappresentano delle stime puntuali per il valore atteso dei 6 campioni considerati, forniamo anche una stima intervallare. Ricordando che stiamo trattando campioni numerosi a varianza incognita, costruiamo un intervallo di confidenza bilatero al livello 95% per il valore atteso relativo a entrambe le gare (solo per il pilota Hamilton) Si noti che, per quanto riguarda la numerosità dei campioni, n_A e n_B non corrispondono esattamente al numero di giri delle due gare, poiché alcuni giri sono stati scartati in quanto outlier, in

ogni caso i campioni rimangono numerosi. (Nel caso di Hamilton, per il GP di Australia gli outlier sono 4, per il GP del Belgio sono 6).

$$IC_{\mu A}(95\%) = (\bar{X}_A - z_{\frac{1+\gamma}{2}} \frac{S_A}{\sqrt{n_A}}, \bar{X}_A + z_{\frac{1+\gamma}{2}} \frac{S_A}{\sqrt{n_A}})$$

$$\begin{aligned} \bar{X}_A &= 8823.7 & S_A &= 747.9121 \\ z_{\frac{1+\gamma}{2}} &= z_{\frac{1+0.95}{2}} = z_{0.975} = 1.96 & n_A &= 57 - 4 = 53 \end{aligned}$$

Sostituendo questi valori, otteniamo $IC_{\mu A}(95\%) = (8622.342, 9025.058)$

$$IC_{\mu B}(95\%) = (\bar{X}_B - z_{\frac{1+\gamma}{2}} \frac{S_B}{\sqrt{n_B}}, \bar{X}_B + z_{\frac{1+\gamma}{2}} \frac{S_B}{\sqrt{n_B}})$$

$$\begin{aligned} \bar{X}_B &= 108916.8 & S_B &= 1445.262 \\ z_{\frac{1+\gamma}{2}} &= z_{\frac{1+0.95}{2}} = z_{0.975} = 1.96 & n_B &= 44 - 6 = 38 \end{aligned}$$

Sostituendo questi valori, otteniamo $IC_{\mu B}(95\%) = (108457.273, 109376, 327)$.

Da entrambe le stime risulta evidente che i valori dei tempi per giro del circuito con più curve e più chilometri sono maggiori.

4.2 Confronto GP Australiano e Cinese

Poniamo a confronto ora la prima gara del campionato, il Gran Premio di Australia, e la seconda, il Gran Premio di Cina:

GP	Curve	Km	Numero di giri	Pioggia
Australia	16	5.303	57	No
Cina	16	5.451	56	Sì

Tabella 12: Confronto caratteristiche Australia e Cina

Notiamo nelle due gare il numero di curve è lo stesso, e il numero di km e di giri è molto simile. Tuttavia la gara del Gran Premio di Cina è caratterizzata da un fattore aggiuntivo: la pioggia. Vediamo i tempi medi per pilota:

GP	Hamilton	Vettel	Bottas
Australia	88223.7	88223.8	88223.9
Cina	97518.24	97737	98008.83

Tabella 13: Confronto tempi medi Australia e Cina

Ci sembra che il fattore pioggia abbia fortemente influenzato i tempi dei piloti, impostiamo un opportuno test d'ipotesi per avvalorare la nostra tesi, cioè $\mu_A < \mu_C$. Consideriamo un pilota alla volta, i due campioni in analisi rappresentano i tempi per giro nelle due gare per il pilota in questione. Si tratta di campioni a varianze incognite, ma indipendenti (riguardano gare diverse) e numerosi. Possiamo dunque procedere con il seguente z-test per campioni indipendenti:

$$\begin{array}{l} \overline{H_0 : \mu_A = \mu_C.} \\ \overline{H_1 : \mu_A < \mu_C.} \end{array}$$

Tabella 14: Test di ipotesi sui tempi medi

Regola decisionale: rifiuto H_0 se $Z_0 < -z_{1-\alpha}$, dove $Z_0 = \frac{\bar{X}_A - \bar{X}_C}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_C^2}{n_C}}}$.

Per tutti e 3 i piloti il p-value risulta bassissimo ($< 2.2e-16$), abbiamo forte evidenza contro H_0 e possiamo accettare con sicurezza H_1 .

Un altro aspetto che ci possiamo aspettare da una gara caratterizzata da un fattore variabile come la pioggia è che sia più difficile per il pilota mantenere un tempo simile per ogni giro. Se la velocità di un pilota varia a seconda delle condizioni metereologiche correnti, si può presumere che in caso di pioggia i tempi si discostino maggiormente dalla gaussianità. Confrontiamo i Q-Q plot delle due gare:




Figura 4.1: Confronto gare di Hamilton con la pioggia




Figura 4.2: Confronto gare di Vettel con la pioggia




Figura 4.3: Confronto gare di Bottas con la pioggia

Shapiro-Wilk normality test

data: H_Australia
 $W = 0.95995$, $p\text{-value} = 0.07305$

(a)

Shapiro-Wilk normality test

data: H_Cina
 $W = 0.92982$, $p\text{-value} = 0.008303$

(b)

Figura 4.4: Shapiro-Wilk Test sui tempi di Hamilton




Figura 4.5: Shapiro-Wilk Test sui tempi di Vettel




Figura 4.6: Shapiro-Wilk Test sui tempi di Bottas

L'inferenza svolta finora ci suggerisce che esista una relazione tra il tempo impiegato per percorrere un giro, la lunghezza del tracciato, il suo numero di curve e il fattore pioggia.

Indaghiamo in modo più approfondito tale relazione servendoci degli strumenti di regressione.

5 Regressione lineare multipla

5.1 Costruzione di un modello

Vogliamo ora dedurre un modello lineare che possa trovare una correlazione tra il tempo impiegato dai piloti per percorrere un giro di pista e le caratteristiche di tale circuito (numero di curve, lunghezza del percorso, numero di giri).

I tempi utilizzati per impostare la regressione corrispondono alle medie aritmetiche calcolate sui tempi leciti dei tre piloti assieme, ovvero escludendo i dati anomali (gli outlier) evidenziati nelle sezioni precedenti per i vari motivi (primo giro, pit-stop, etc.), per di più possiamo ritenere questi tempi tutti indipendenti tra loro, non essendoci ragioni affinché si influenzino tra di loro.

La prima realizzazione del modello che abbiamo ipotizzato è stata, per semplicità, una legge lineare che include tutti i predittori: come primo approccio, li abbiamo ritenuti indipendenti tra loro, dal momento che, da non esperti del settore, non conosciamo una evidente relazione tra loro; inoltre considereremo i residui del modello gaussiani centrati su 0.

Mostriamo di seguito l'esito dell'elaborazione del calcolatore con i relativi grafici dei residui e del Q-Q Plot, che mette a confronto i quantili teorici della normale standard con quelli provenienti dalle realizzazioni:

```
Call:
lm(formula = tempi ~ curve + km + giri)

Residuals:
    Min       1Q   Median       3Q      Max
-8804.1 -3453.2  -250.2   3965.2  9376.6

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 145970.3    100729.8   1.449  0.169330
curve         2004.7       422.5    4.744  0.000314 ***
km          -3815.3       9004.5   -0.424  0.678217
giri         -1134.9        859.5   -1.320  0.207859
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5096 on 14 degrees of freedom
Multiple R-squared:  0.8636, Adjusted R-squared:  0.8344
F-statistic: 29.55 on 3 and 14 DF,  p-value: 2.587e-06
```

Figura 5.1: Resoconto del primo modello




Figura 5.2: Residui e Quantili del primo modello

In prima osservazione possiamo dire che il modello ha un coefficiente di determinazione accettabile (***Adjusted R-squared***: 0.8344) e spiega bene la variabilità dei tempi impiegati, inoltre è globalmente significativo (***p-value F-statistic***: 2.587e-06); dunque possiamo constatare che i regressori in questione hanno una qualche incidenza. Riguardo lo scatterplot dei residui standardizzati, essi si dispongono senza individuare un pattern specifico, confermando le ipotesi di omoschedasticità e indipendenza dei residui, inoltre è presente un unico dato al di fuori dell'intervallo $[-2, 2]$; inoltre, dall'osservazione del secondo grafico, i risultati sono veramente positivi: i quantili tendono fortemente ad allinearsi attorno alla retta e lo Shapiro-test dà alte conferme di ciò e ci suggerisce che il percorso da noi intrapreso ha fondamenta. Però a rendere il modello inaccurato e quindi da scartare sono i singoli p-value delle variabili indipendenti: troppo alti per ritenere il modello completo.

A tale scopo cerchiamo di migliorare le variabili indipendenti in gioco: vogliamo essere certi che i predittori in questione non si influenzino tra di loro, ovvero che non ci troviamo in un caso di collinearità. Perciò osserviamo gli scatterplot tra i dati di queste caratteristiche:




Tabella 15: Variabili indipendenti in relazione tra loro

Risulta particolarmente evidente che solo la lunghezza del percorso e il numero di giri hanno una qualche relazione tra di loro: infatti, è immediato pensare che un circuito corto avrà più giri rispetto a un circuito più lungo. Dunque, scarteremo le informazioni provenienti dal numero di giri e ci concentreremo solo sui regressori *numero di curve* e *lunghezza del percorso* per costruire un modello lineare per il tempo medio.

Il resoconto che otteniamo è il seguente:

```

Call:
lm(formula = tempi ~ km + curve)

Residuals:
    Min       1Q   Median       3Q      Max
-7.3750 -4.0216 -0.9438  3.2278 11.3922

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  13.4493     8.8465   1.520 0.149235
km           7.9081     1.5399   5.135 0.000122 ***
curve        2.2351     0.3942   5.670 4.45e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.221 on 15 degrees of freedom
Multiple R-squared:  0.8466, Adjusted R-squared:  0.8262
F-statistic: 41.4 on 2 and 15 DF, p-value: 7.813e-07

```

Figura 5.3: Resoconto secondo modello




Figura 5.4: Residui e Quantili del secondo modello

Questo modello ci permette di riconfermare le osservazioni precedenti, ovvero che la lunghezza del percorso e il numero di curve incidono sul risultato del tempo impiegato, ma soprattutto hanno fortissima rilevanza (segnalato con tre asterischi nel summary). I residui risultano indipendenti tra loro e identicamente distribuiti e il grafico quantile-quantile mostra una tendenza nettamente migliore. L'unico neo da tener d'occhio è sicuramente il valore dell' $R^2_{Adjusted}$, che è poco sopra della soglia minima di accettazione dell'81%.

Presentiamo ora il seguente modello, il penultimo, che permette di migliorare le fragilità che caratterizzavano il precedente: in questo modello abbiamo introdotto una trasformazione logaritmica sui dati di tempo e chilometri percorsi, così che si adattasse meglio l'intercetta della retta di regressione.

```

Call:
lm(formula = log(tempi) ~ log(km) + curve)

Residuals:
    Min       1Q   Median       3Q      Max
-0.07574 -0.03653 -0.01291  0.03454  0.09472

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.352067    0.122195  27.432 3.11e-14 ***
log(km)       0.457283    0.074055   6.175 1.78e-05 ***
curve        0.024676    0.003828   6.447 1.10e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.05122 on 15 degrees of freedom
Multiple R-squared:  0.8776, Adjusted R-squared:  0.8613
F-statistic: 53.79 on 2 and 15 DF, p-value: 1.437e-07

```

Figura 5.5: Rasoconto terzo modello




Figura 5.6: Residui e Quantili terzo modello

Constatiamo che il modello ottiene un notevole progresso relativamente all'intercetta e ai singoli predittori, ma perde nitidezza attorno ai quantili dei residui, il p-value del Shapiro Test si abbassa e l'aderenza alla retta non è troppo convincente: nonostante il modello in questione rispetti tutte l'ipotesi di omoschedasticità, il 95% dei dati si trova all'interno dell'intervallo appropriato e la gaussianità degli errori non possa essere scartata, non crediamo che il modello spieghi nella sua interezza la relazione tempi dei piloti, lunghezza del percorso e numero di curve.

Integriamo, allora, all'interno del modello una nuova variabile, indipendente dalle altre e completamente aleatoria: le condizioni meteorologiche in cui i gran premi si sono svolti. Esponiamo quindi l'ultimo modello, quello definitivo,

con relativi grafici valori stimati-residui, quantile-quantile e riepilogo con il commento completo.

```
Call:
lm(formula = log(tempi) ~ log(km) + curve + curve:piove)

Residuals:
    Min       1Q   Median       3Q      Max
-0.061188 -0.023350 -0.003070  0.009549  0.069020

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  10.289753    0.097108  105.962 < 2e-16 ***
log(km)       0.471333    0.058739   8.024 1.32e-06 ***
curve        0.026036    0.003058   8.515 6.58e-07 ***
curve:pioveS -0.005216    0.001651  -3.159 0.00696 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04051 on 14 degrees of freedom
Multiple R-squared:  0.9286, Adjusted R-squared:  0.9133
F-statistic: 60.66 on 3 and 14 DF, p-value: 2.889e-08
```

Figura 5.7: Resoconto modello definitivo




Figura 5.8: Residui e Quantili modello definitivo

Il modello è regolato dalla seguente legge, dove il livello piove $P = 0$ e il livello sereno $S = 1$:

$$\log(\text{tempi}) = \beta_0 + \beta_1 \cdot \log(\text{km}) + \beta_2 \cdot \text{curve} + \beta_3 \cdot \text{curve} \cdot \text{piove}$$

Innanzitutto, commentiamo le ipotesi di applicabilità del modello lineare: i residui sono omoschedastici, disposti a nuvola attorno all'asse orizzontale e tutti

sono compreso tra $+2$ e -2 , il qq-plot e lo SW test ci suggeriscono la normalità dei residui del campione, seppur presente una sbavatura nella coda destra che nel complesso non risulta così influente. Successivamente, spieghiamo la legge che governa questo modello: abbiamo inserito la variabile categorica della pioggia (piove o non piove) nell'interazione con le curve, dal momento che, in caso di precipitazione, un pilota deve intraprendere una curva con maggior cautela a causa del fenomeno di aquaplaning, ovvero di slittamento su uno strato esteso di acqua. Riteniamo, invece, che la pioggia non incida particolarmente sulla lunghezza di un circuito come abbiamo potuto sperimentare in altri modelli. Inoltre, dall'output di R abbiamo ulteriori conferme sulla spiegazione della variabilità dei dati $R^2_{Adjusted} = 0.9133$, distante solo un punto percentuale dal R quadro multiplo, e sull'incidenza di tutti i regressori considerati.

5.2 Previsione sugli ultimi tempi

Da ultimo, collaudiamo il nostro modello con le ultime due circuiti della stagione 2017 di Formula 1: realizziamo un intervallo di predizione di livello $\alpha = 0.95$ e verifichiamo se la media dei tempi leciti della gara n°19 e la n°20 vi cada all'interno tramite l'utilizzo di R. Per il Gran Premio del Brasile il valore predetto e l'intervallo di predizione, su cui poi applicare l'esponenziale, sono:

fit	lwr	upr
4.382782	4.290653	4.474912

Il valore reale di 4.297 realmente effettuato appartiene all'intervallo di predizione, dunque il modello funziona, anche se è da ammettere che la predizione, che corrisponde a un tempo di 80.06 s, superi di oltre 5 secondi il tempo medio, forse troppi in un contesto professionale così importante.

Allora, effettuiamo un secondo test sull'ultima gara dell'anno, tenutasi ad Abu Dhabi: l'elaborazione riporta il seguente risultato:

fit	lwr	upr
4.627335	4.532218	4.722451

Esiti molto più soddisfacenti, dal momento che identificano un tempo medio di 102.24 s, dato che si distacca solo di 2 decimi di secondo da quello attuato nella realtà. A seguito di questi risultati possiamo ritenerci soddisfatti su come il modello da noi ipotizzato funzioni, aderisca alla realtà e sia in grado di stimare il tempo ideale di un circuito. Infine, ci teniamo anche a evidenziare che, nonostante il vincitore del campionato mondiale fosse stato già decretato, le ultime due gare sono state percorse con serietà e senza strategie, all'insegna dello sport e dello spettacolo.

6 Conclusioni

Gli studi effettuati ci hanno permesso di evincere che esiste una legge che governa il tempo di percorrenza di un circuito. Nonostante siamo stati in grado di trovare un modello che nella sua semplicità sia in grado di stimare il tempo medio dei tre piloti in questione con una discreta bontà e, dunque, l'obiettivo del progetto è stato raggiunto, siamo consci del fatto che la realtà è ben più articolata: infatti, siamo certi che per descrivere nella sua completezza i risultati dei tempi ottenuti nei gran premi entrano in gioco alcuni fattori più complessi che nella nostra analisi non abbiamo considerato.

Perciò, siamo consapevoli di aver indagato solo in superficie, ma anche di avere gettato le fondamenta per una ricerca con ulteriori evoluzioni e con possibili sviluppi: per esempio, fare regressione sui tempi più veloci realizzati nell'arco della stagione, dato singolo e non soggetto a fluttuazioni significative, mettere in correlazione il modello da noi costruito con i tempi delle qualifiche oppure ancora considerare la tipologia di ruote utilizzate in relazione alle condizioni meteorologiche.

In definitiva, questo studio ci ha permesso di migliorare le nostre competenze in materia, confrontarci con una vera indagine statistica e con tutti gli ostacoli che essa comporta, ma anche con le grandi soddisfazioni e l'entusiasmo che progetti intensi come questo regalano.

7 Bibliografia e Risorse

- Organizzazione del progetto
 - <https://www.formula1.com/en.html>
 - <https://hal.archives-ouvertes.fr/hal-01343716/document>
 - <https://theoehrly.github.io/Fast-F1/core.html#fastf1.core.Lap>
 - <https://www.statsf1.com/it/2017.aspx>
- Dataset
 - <https://www.kaggle.com/datasets/cjgdev/formula-1-race-data-19502017>
 - <https://rpubs.com/robby0610/392727>
- Software utilizzati:
 - R
 - MatLab
 - L^AT_EX
 - Advanced Boxplot Maker
 - Onlinecharttool